TP
Data Warehouse

Corentin MARQUET
Adrien GUIBON

Groupe 3

I. Problématique

Bienvenue dans le TP Data Warehouse du groupe numéro 3. Dans l'actualité récente, nous avons pu entendre parler de la problématique des déserts médicaux, avec une proposition de loi visant à imposer aux médecins généralistes deux jours de consultation par semaine en désert médical. Dans ce cadre, nous nous sommes posés la question suivante : Quels sont les facteurs influençant la répartition géographique des médecins généralistes au niveau départemental en France métropolitaine ? Nous avons décidé de nous concentrer sur la France métropolitaine, car les jeux de données que nous avons trouvés n'intégraient pas tous des statistiques sur les territoires d'outre-mer.

II. Méthodologie

Pour cela, nous avons récupéré les données suivantes (à chaque fois au niveau des départements) :

- taux de chômage,
- nombre de délits et crimes,
- jours d'ensoleillement par an,
- données immobilières (notamment prix au m²),
- infrastructures (commerces, loisirs, enseignement, transports…),
- revenus fiscaux,
- solde migratoire,
- liste des villes avec leurs paramètres associés.

A) Sources de données

Ci-après, nous allons détailler plus précisément les sources de données utilisées et quelles complications éventuelles elles ont pu poser :

Répartition_médecin_département.xlsx	Fichier Excel, nécessitant l'emploi de la fonction adaptée de la librairie Pandas. Header situé sur la cinquième ligne (que l'on peut indiquer au moment de l'importation). Nous avons décidé d'utiliser la colonne « Ensemble des médecins pour 100 000 habitants » afin de normaliser le nombre de médecins par rapport à la population du département en question.
Criminalité.csv	Nous avons le nombre des différents types d'infractions par département sur plusieurs années. Nous préférons utiliser un taux de criminalité, et pour cela nous avons dû dans notre ETL filtrer sur l'année 2024, puis grouper les données par département en additionnant ensemble les différents taux pour chaque infraction.

Ensoleillement.csv	Les départements sont représentés par leur nom et non pas par leur numéro. Dans l'ETL, nous avons créé une fonction afin de normaliser le nom des départements (remplacement des tirets et des apostrophes par des espaces, suppression des accents), que nous avons appliquée à la colonne concernée dans ce fichier, mais aussi dans le fichier de la répartition des médecins par département (qui contient aussi une colonne avec les noms des départements) afin de pouvoir les fusionner ensemble. Les données concernant la Corse et l'Eure-et-Loir ne sont pas disponibles.
Immobilier.csv	Nous avons des données de transactions immobilières par commune. L'ETL reprend les deux premiers chiffres du code postal (pour obtenir le département) puis regroupe les données par département en faisant la moyenne du prix au mètre carré. Les données pour les départements de la Moselle, du Bas-Rhin et du Haut-Rhin ne sont pas disponibles.
Infrastructures.csv	Fichier imposant, faisant la liste des infrastructures sur le territoire français (services, commerces, lieux d'enseignement, santé et action sociale, transports, sports, loisirs et culture, tourisme). L'ETL filtre les lignes dont la colonne « GEO_OBJECT » contient la valeur « DEP » (numéro de département). Ensuite, nous avons une colonne « FACILITY_DOM » qui correspond aux différentes catégories d'infrastructures, représentées par une lettre (A, B, C, D, E, F, G). L'ETL groupe les lignes par département en fonction de ces lettres, pour connaître le nombre de fois où chacune apparaît pour chaque département. Il faut ensuite faire un pivot afin de mettre sur la première colonne (l'index) les département et sur le header chaque lettre (correspondant donc à un type d'infrastructure).
Codes_DOM.csv	Ce fichier permet de remplacer les lettres des infrastructures par leur description. Nous l'avons transformé en dictionnaire Python.

Revenus_fiscaux.xlsx	Fichier Excel, nécessitant l'emploi de la fonction adaptée de la librairie Pandas. Header sur la fusion des lignes 6 et 7. Nous avons ici des données fiscales pour différentes tranches de revenus, pour chaque commune. Tout d'abord, nous avons filtrer seulement les lignes contenant les totaux (pour enlever celles avec les différentes tranches de revenus). Nous avons ensuite créé une fonction pour normaliser les nombres : remplacement des virgules par des points, remplacement des valeurs non renseignées (« *n.c.* », « *nc* ») par des valeurs vides (*np.nan*), transformation en type *float*. Cette fonction a été appliquée aux colonnes « *Revenu fiscal de référence des foyers fisc*aux » et « *Nombre de foyers fiscaux* » (car nous allons faire des opérations dessus par la suite). Nous avons également dû créer une fonction pour normaliser les numéros des départements, qui étaient sous la forme « XXX », par exemple « 010 » pour le département 01, alors que nous les voulions seulement à deux chiffres. Finalement, nous avons groupé par département en divisant le revenu fiscal de référence des foyers fiscaux par le nombre de foyers fiscaux (pour normaliser).
Villes.csv	Liste des différentes villes de France. Nous avons groupé par département, en comptant le nombre de villes ayant plus de 10 000 habitants, en prenant la moyenne de la population par villes ainsi que la moyenne de la densité.
Solde_migratoire.xlsx	Ce fichier Excel est composé de différentes feuilles. Celle qui nous intéresse est « Territoire - Figure 1 » qui représente la variation annuelle de la population par département entre 1968 et 2021. Le header commence à la ligne 4.
Chomage.csv	Contient les taux de chomage par trimestre par département depuis 1982. L'ETL filtre seulement sur la colonne du dernier trimestre de 2024.

L'ETL ajoute par ailleurs un code ISO afin de construire les cartes sur Superset. Nous avions aussi pensé à recueillir les données de pluviométrie mais toutes les sources ne fournissaient que des datasets pour chaque département pris individuellement, ce qui rendait leur traitement assez laborieux.

B) Modèle en étoile

Voici le modèle en étoile que nous avons utilisé :

- **installationMedecinsFait**(FK codeDepartement, nombreMedecins)
- **departementDimension**(PK codeDepartement, nomDepartement, codeISO)
- **attractiviteDimension**(PK codeDepartement, tauxCriminalite, tauxEnsoleillement, prixM2Moyen)
- **populationDimension**(PK codeDepartement, evolutionPopulation, densiteMoyenneHabitants, populationTotale, nombreVillesSup10k)
- **economieDimension**(PK codeDepartement, revenuMoyenParFoyer, tauxChomage)
- **infrastructuresDimension**(PK codeDepartement, services, commerces, enseignement, santeEtActionSociale, transports, sportsLoisirsCulture, tourisme)

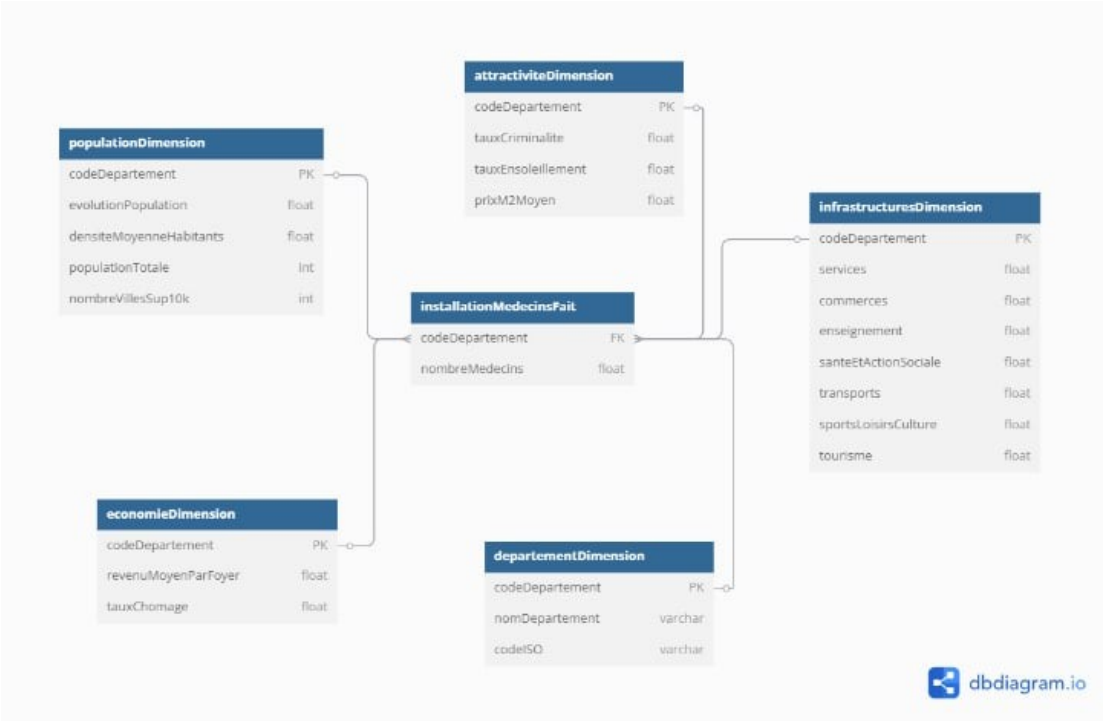

C) Schéma d'architecture logicielle

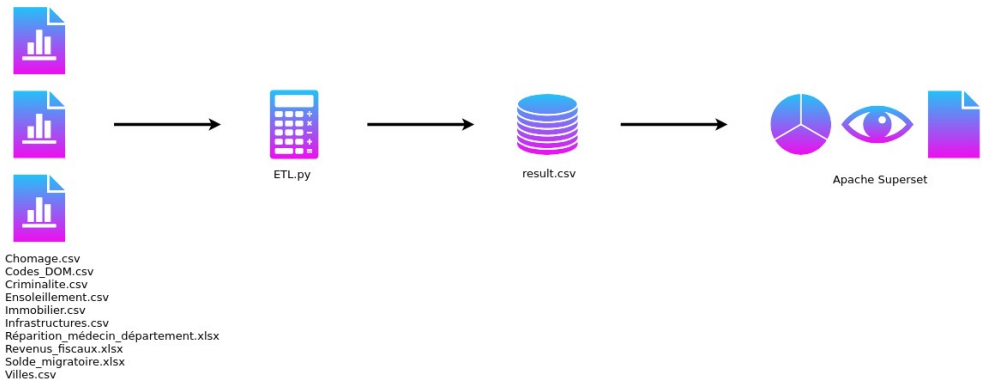

D) Visualisation

Nous avons ensuite importé les données dans Apache Superset. Pour commencer, nous avons réalisé plusieurs cartes de la France représentant la densité médicale, le nombre d'infrastructures et la densité de population. Il fallait pour cela avoir une colonne ISO 3166 suivie des deux chiffres du département pour chaque ligne. Pour les infrastructures, nous avons dû utiliser SQL Lab pour faire une moyenne de toutes les infrastructures (nous aurions pu aussi le faire dans le script Python) :

```
AVG(
  "decile_services" +
  "decile_commerces" +
  "decile_enseignement" +
  "decile_santeetactionsociale" +
  "decile_transports" +
  "decile_sportsloisirsculture" +
  "decile_tourisme"
) / 7.0
```

Pour la densité de population et la densité médicale, nous avons regroupé les données par déciles afin qu'elles soient plus faciles à visualiser :

```
SELECT
    *,
    NTILE(10) OVER (ORDER BY "nombreMedecins") AS decile_nombreMedecins,
    NTILE(10) OVER (ORDER BY "densiteMoyenneHabitants") AS
decile_densitemoyennehabitants,
FROM "public"."medecinsVF"
```

Nous avons également créé un *Box Plot* de la densité médicale en fonction du prix moyen du mètre carré. Pour avoir des déciles avec des noms suffisamment évocateurs, nous avons employé cette requête sur SQL Lab :

```
SELECT
  *,
  CASE
    WHEN "prixM2Moyen" <= 1318.51 THEN '1053–1318 €'
    WHEN "prixM2Moyen" <= 1424.76 THEN '1318–1424 €'
    WHEN "prixM2Moyen" <= 1631.70 THEN '1424–1631 €'
    WHEN "prixM2Moyen" <= 1746.08 THEN '1631–1746 €'
    WHEN "prixM2Moyen" <= 1890.44 THEN '1746–1890 €'
    WHEN "prixM2Moyen" <= 2042.81 THEN '1890–2042 €'
    WHEN "prixM2Moyen" <= 2205.99 THEN '2042–2205 €'
    WHEN "prixM2Moyen" <= 2400.31 THEN '2205–2400 €'
    WHEN "prixM2Moyen" <= 2734.75 THEN '2400–2734 €'
    ELSE                              '2734–9999 €'
  END AS decile_prixm2_label
FROM "public"."medecinsVF";
```

Nous avons aussi utilisé un *Line Chart* pour montrer la densité médicale en fonction du taux d'ensoleillement. Pour limiter le nombre des valeurs et l'influence des extrêmes, nous avons fait des moyennes par tranches de 25 heures d'ensoleillement :

```
SELECT
  ROUND("tauxEnsoleillement" / 25.0) * 25 AS tranche_ensoleillement,
  AVG("nombreMedecins") AS densite_medicale_moyenne
FROM "public"."medecinsVF"
WHERE "tauxEnsoleillement" IS NOT NULL
GROUP BY tranche_ensoleillement
ORDER BY tranche_ensoleillement
```

Nous avons eu recours à des *Scatter Plot* pour la densité médicale en fonction du taux de criminalité et du revenu moyen par foyer ainsi qu'un *Bar Chart* pour l'évolution de la population en fonction de la densité médicale. Pour terminer, nous avons fait un histogramme des taux de chômage pour différentes tranches de densité médicale. Nous avons utilisé la fonction cumulative afin de mieux visualiser la répartition des taux de chômage au sein de chaque tranche de densité médicale. Pour que les barres d'histogramme s'affichent dans le bon ordre (alphabétique), nous avons dû utiliser cette requête :

```
SELECT
  *,
  CASE
    WHEN "tauxChomage" <= 6.6 THEN '01 - 6.0–6.6 %'
    WHEN "tauxChomage" <= 7.2 THEN '02 - 6.6–7.2 %'
    WHEN "tauxChomage" <= 7.7 THEN '03 - 7.2–7.7 %'
    WHEN "tauxChomage" <= 8.1 THEN '04 - 7.7–8.1 %'
    WHEN "tauxChomage" <= 8.5 THEN '05 - 8.1–8.5 %'
    WHEN "tauxChomage" <= 9.0 THEN '06 - 8.5–9.0 %'
    WHEN "tauxChomage" <= 9.5 THEN '07 - 9.0–9.5 %'
    WHEN "tauxChomage" <= 10.0 THEN '08 - 9.5–10.0 %'
    WHEN "tauxChomage" <= 10.6 THEN '09 - 10.0–10.6 %'
    ELSE '10 - >10.6 %'
  END AS decile_tauxchomage_label
FROM "public"."medecinsVF"
```

III. Interprétation

Avant de commencer, nous devons préciser que certains graphes utilisés ne sont pas forcément les plus adaptés, mais que nous l'avons quand même fait afin de répondre aux exigences du TP concernant notre capacité à utiliser différentes représentations de données. De plus, nous ne pouvons faire que des corrélations et non pas des causalités via l'exploitation de ces graphiques.

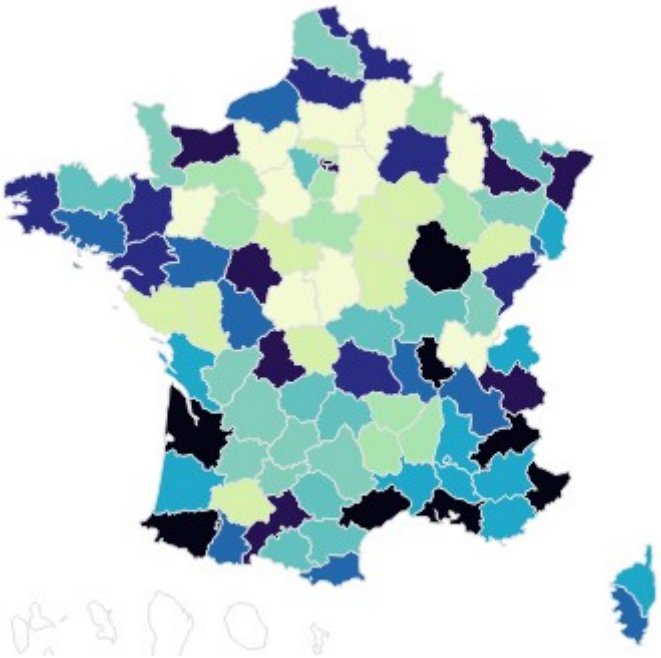

Densité médicale

Nous pouvons commencer avec la carte de la France qui montre la densité médicale par département. On peut observer un fort contraste entre départements, avec une densité plus marquée au niveau de certains centre urbains (Paris, Sud-Est, région lyonnaise) et des littoraux. À l'inverse, elle est plus faible au niveau des territoires ruraux.

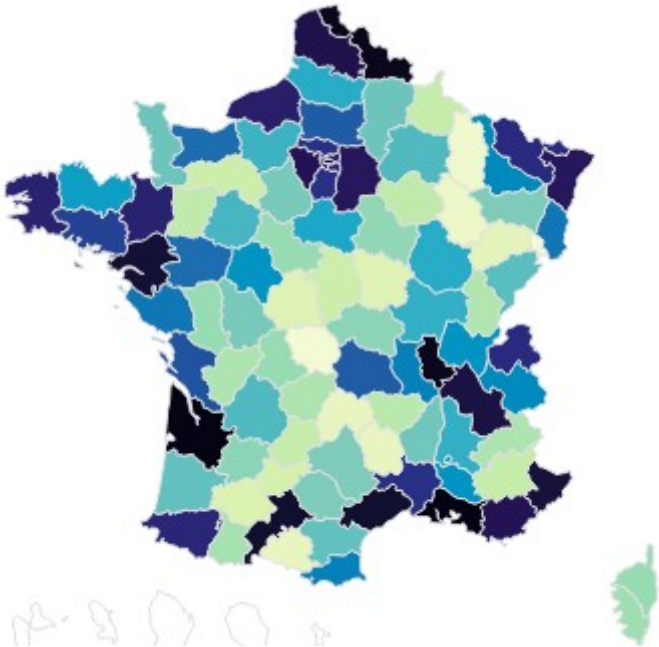

Infrastructures

Il semble y avoir une certaine corrélation visuelle entre le nombre d'infrastructures total et la densité médicale, sauf en ce qui concerne l'Île-de-France en dehors de Paris.

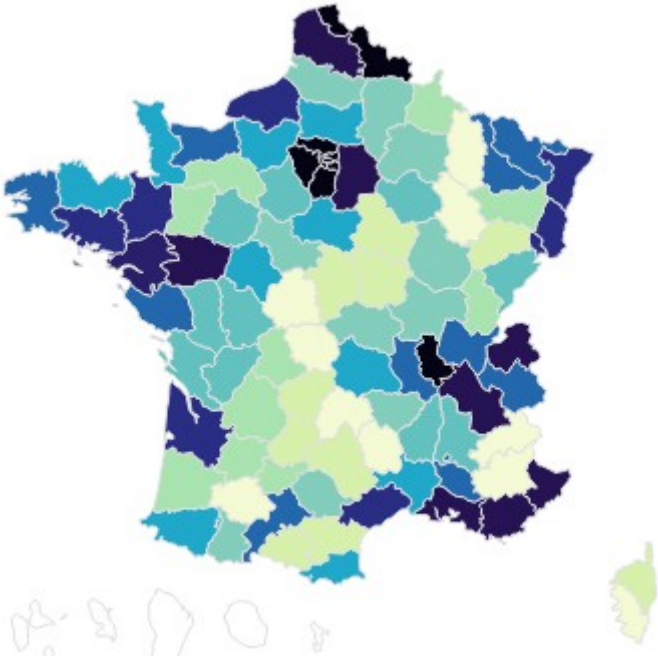

Densité de population

De même, une plus forte densité de population semble être associée à une densité médicale plus élevée, sauf encore une fois au niveau de l'Île-de-France en dehors de Paris.

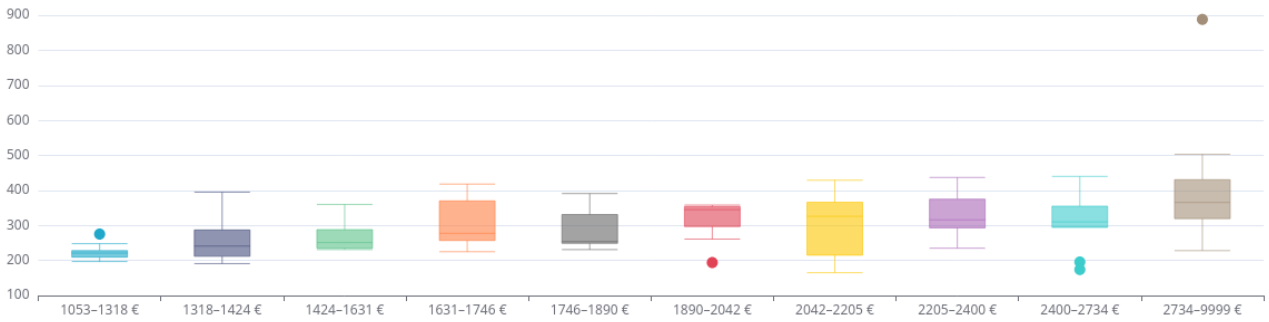

Nous avons ici le *box plot* représentant la densité médicale en fonction du prix moyen du mètre carré. Il semble y avoir une densité médicale plus élevée dans les zones où l'immobilier est plus cher. Cela pourrait refléter un certain attrait pour les zones urbaines et économiquement favorisées, même si on peut aussi voir certaines zones à immobilier plus abordable avec une densité correcte.

Mais quand on regarde le *scatter plot* de la densité médicale en fonction du revenu moyen par foyer, on s'aperçoit que la corrélation est cependant très faible voire absente, en dehors de l'outlier représenté par Paris.

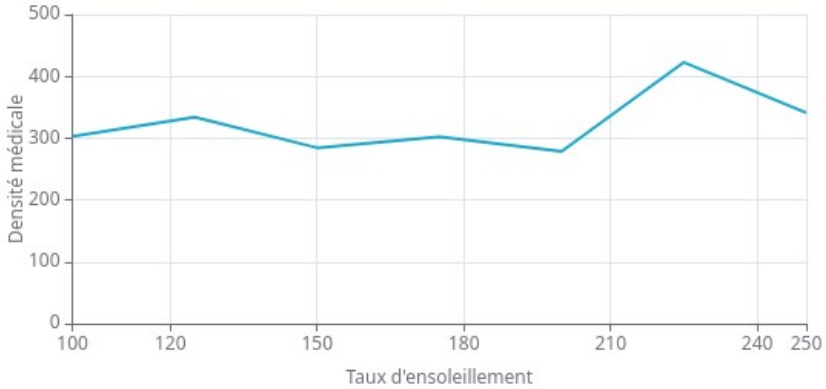

Ce *line chart* de la densité médicale en fonction du taux d'ensoleillement a une courbe relativement plate, reflet d'une corrélation étonnamment assez faible, avec tout de même une légère hausse dans les zones très ensoleillées.

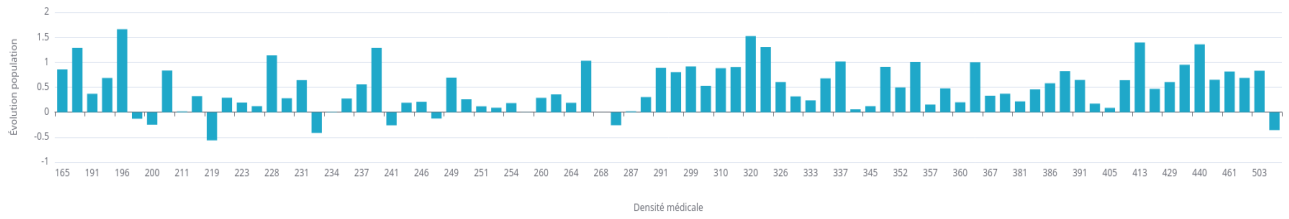

Sur ce *bar chart* de l'évolution de la population en fonction de la densité médicale, on peut voir une certaine corrélation positive : les départements avec une forte densité médicale ont tendance à voir leur population augmenter (sauf pour Paris).

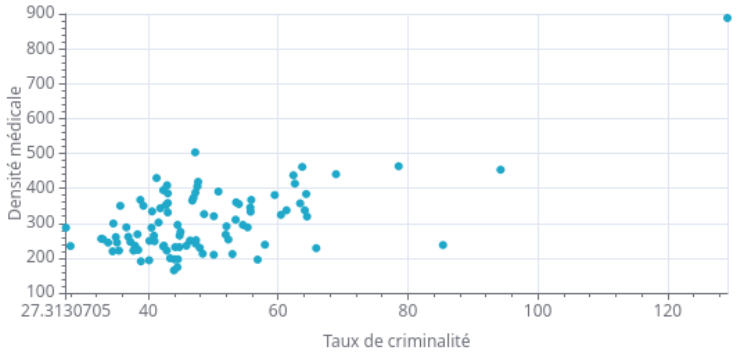

Ici, nous pouvons voir la densité médicale en fonction du taux de criminalité, et il ne semble pas y avoir de relation évidente entre ces deux paramètres (sauf encore une fois pour Paris). Cela suggère que la criminalité n'est pas un paramètre important dans le choix d'installation des médecins.

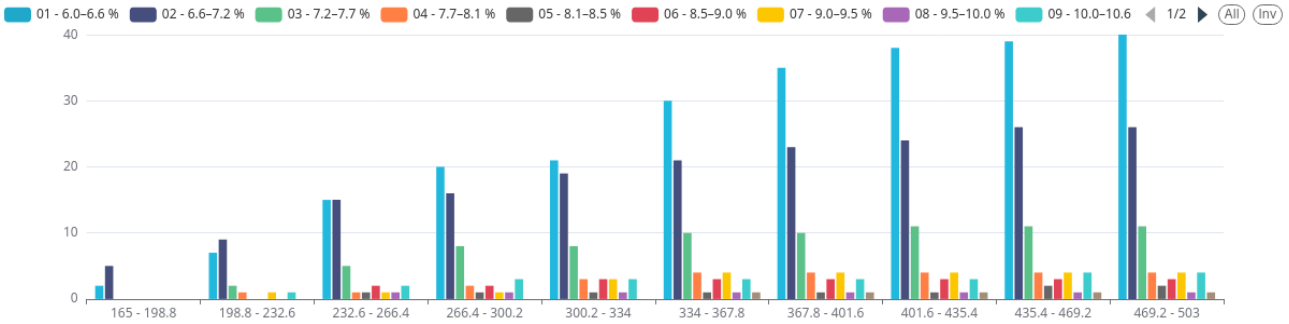

Nous pouvons enfin terminer par l'histogramme des taux de chômage par tranches de densité médicale. On remarque que les tranches à faible densité médicale semblent être associées à des taux de chômage plus élevés. Encore une fois, les médecins ont tendance à s'installer dans les zones plus dynamiques économiquement.

Pour synthétiser, les facteurs avec lesquels on observe une corrélation positive avec la répartition départementale des médecins semblent être :

- la densité de population et les zones avec augmentation du nombre d'habitants (logique de demande),
- la présence d'infrastructures (installation favorisée dans les zones mieux équipées),
- le prix de l'immobilier (les zones chères attirent plus de médecins),
- le taux de chômage (les médecins évitent les zones économiquement défavorisées).

En revanche, nous n'observons pas de relation claire avec le taux d'ensoleillement, le revenu moyen par foyer et avec la criminalité.